

## Day 2. GMM : Gaussian Mixture Model

### A. Multivariate Gaussian Distribution

1. Vector to normal distribution.

$$x \in \mathbb{R}^d, N(x; \mu, \Sigma)$$

\* Gaussian Distribution func of  $x$

$$N(x; \mu, \Sigma) = \frac{1}{\sqrt{(2\pi)^d |\Sigma|}} e^{\{-\frac{1}{2}(x-\mu)^T \overset{\text{inverse}}{\Sigma^{-1}}(x-\mu)\}}$$

$\hookrightarrow \det(\Sigma)$

\* Covariance matrix & variable relationship

$x$ :  $n$ -dim vector

$\mu$ : mean vector

$\Sigma$ : covariance matrix

2. MLE (Modeling as multivariate Gaussian Distribution)

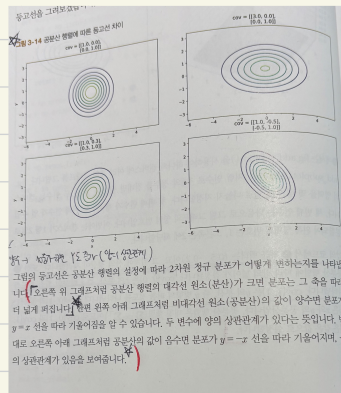
$$D = \{x^{(1)}, x^{(2)} \dots x^{(N)}\}$$

• Gaussian Modeling을 하고, 매개변수가  $\mu, \Sigma$  일때 샘플  $D$ 를 얻을 수 있는 확률밀도 : 가우

$$p(D; \mu, \Sigma) = N(x^{(1)}; \mu, \Sigma) N(x^{(2)}; \mu, \Sigma) \dots N(x^{(m)}; \mu, \Sigma) \quad (\text{iid} \rightarrow \text{multiplication})$$

$$= \prod_{n=1}^N N(x^{(n)}; \mu, \Sigma)$$

$$= L(\mu, \Sigma)$$



$$\cdot \log |\Sigma|$$

$$\therefore L(\mu, \Sigma) = \log p(D; \mu, \Sigma)$$

• Maximize?

$$\frac{\partial L}{\partial \mu} = 0, \quad \frac{\partial L}{\partial \Sigma} = 0 \quad \left( \frac{\partial L}{\partial \mu} \in \mathbb{R}^d, \quad \frac{\partial L}{\partial \Sigma} \in \mathbb{R}^{d \times d} \right)$$

The  $\hat{\mu}, \hat{\Sigma}$  that maximize the  $L(\mu, \Sigma) = \log p(D; \mu, \Sigma)$  are "sample" mean vector & "sample" covariance matrix.

## B. GMM: Gaussian Mixture Model

- GMM is a model with multiple Gaussian distributions.

• Generative model that follows GMM

1) GMM modeling

2) Parameter Estimation  $\rightarrow$  "EM algorithm"

✕ PB review: Joint probability & marginal probability & conditional probability

• J.P:  $p(x, y)$ ,  $x, y$ 가 동시에 나올 확률

• Marginalize: 한쪽에서 특정 확률변수 제거

• Discrete:  $p(x) = \sum_y p(x, y)$

• Continual:  $p(x) = \int p(x, y) dy$

• C.P:  $p(x, y) = \underbrace{p(x|y)}_{\text{C.P}} p(y)$

## Sampling in GMM

① 입수된 파라미터에 따라 각 클러스터로부터 샘플링

② 선택된 클러스터로부터 generate data

⇒ iterate ①, ② for  $N$  times

## \* $P(x)$ for GMM

### Categorical Distribution in GMM

$p(z=k; \phi) = \phi_k / \sum_k \phi_k$  (parameter for categorical distribution), where  $k$  is a # of G.D in GMM

①  $\forall k, \phi_k \geq 0$

②  $\sum_k \phi_k = 1$

### $\mu, \Sigma$ for multiple G.D

$\mu = \{\mu_1, \mu_2, \dots, \mu_K\}$

$\Sigma = \{\Sigma_1, \Sigma_2, \dots, \Sigma_K\}$

### Probability density value of $x$ in $k^{th}$ G.D

$p(x | z=k; \mu, \Sigma) = N(x; \mu_k, \Sigma_k)$

### Induce $p(x)$ from $p(x, z)$ by marginalization.

$p(z=k; \phi) = \phi_k \dots ①$

$p(x | z=k; \mu, \Sigma) = N(x; \mu_k, \Sigma_k) \dots ②$

$p(x, z=k) = p(z=k) p(x | z=k) \dots ③$

$p(x) = \sum_{k=1}^K p(x, z=k)$

$\therefore p(x) = \sum_{k=1}^K \phi_k N(x; \mu_k, \Sigma_k)$  "  $p(x)$  for GMM is a weighted summation of P.D in each distribution "

\*  $x$ 는 관측된 값이지만  $z$ 는 관측되지 않은 값이므로, 잠재변수 (latent variable) 라고 한다.

## \* Parameter estimation for GMM

$$p(x) = p(x; \phi, \mu, \Sigma) \\ = \sum_{k=1}^K \phi_k N(x; \mu_k, \Sigma_k)$$

$$D = \{x^{(1)}, x^{(2)} \dots x^{(N)}\}, \theta = \{\phi, \mu, \Sigma\}$$

$$p(D; \theta) = p(x^{(1)}; \theta) p(x^{(2)}; \theta) \dots p(x^{(N)}; \theta) \\ = \prod_{n=1}^N p(x^{(n)}; \theta)$$

↓ log

$$\underline{L(\theta)} = \log p(D; \theta) = \log \prod_{n=1}^N p(x^{(n)}; \theta)$$

likelihood of  
D under GMM model

$$= \sum_{n=1}^N \log p(x^{(n)}; \theta)$$

$$= \sum_{n=1}^N \log \left( \sum_{k=1}^K \phi_k N(x^{(n)}; \mu_k, \Sigma_k) \right)$$

$\therefore \arg \max_{\theta} L(\theta)$ , where  $\theta = \{\phi, \mu, \Sigma\}$  : 로그가능도를 최대화 하는  $\theta$ 를 찾는 것이 목표!

$$\Leftrightarrow \text{Solve } \frac{\partial L}{\partial \phi} = 0, \frac{\partial L}{\partial \mu} = 0, \frac{\partial L}{\partial \Sigma} = 0!$$

- Cannot solve  $\frac{\partial L}{\partial \phi}, \frac{\partial L}{\partial \mu}, \frac{\partial L}{\partial \Sigma} = 0$  해석적으로 풀기 X  $\Rightarrow$  Use EM Algorithm.  
(해석적으로 풀기 X)

$\Rightarrow$  why?

latent variable Z로 인해 특정 데이터 x에 대한  $p(x|\theta)$ 가 Z형태를 띠고, 결과적으로 샘플 D에 대한 전체 우도  $L(D; \theta)$ 가 log-sum 형태가 되어, 해석적으로 MLE를 구할 수 없게 된다.

샘플 데이터에서 관측되지 않은 잠재 변수 Z로 인해, 특정 데이터 x에 대한 우도  $p(x; \theta)$ 가 \*\*합(summation)\*\*의 형태를 띠고, 결과적으로 샘플 D에 대한 전체 우도  $L(D; \theta)$ 가 log-sum 형태가 되어, 해석적으로 MLE를 구할 수 없게 된다.